



随机过程及应用

Stochastic Process with its Applications

彭江艳 数学科学学院

(教授 博士生导师)

办公室:

清水河校区主楼6号科研楼A557

电邮:

`pengjiangyan@uestc.edu.cn`

个人主页:

导师个人信息 - 电子科大研招(uestc.edu.cn)

<https://yjsjy.uestc.edu.cn/gmis/jcsjgl/dsfc/dsgrjj/11400?yxsh=11>

<https://www.math.uestc.edu.cn/info/1077/1947.htm>





课程信息

●上课时间及教室:

周一下午 16:20-17:55(7-8节), 沙河校区二楼306(8班)

周三下午 16:20-17:55(7-8节), 沙河校区二楼306(8班)

●教材: 随机过程及应用, 徐全智等主编, 高等教育出版社








●参考书目: S. M. Ross. 应用随机过程. 北京, 人民邮电出版社








陆大乡 金. 随机过程及其应用. 北京, 清华大学出版社

方兆本 廖柏其. 随机过程. 北京, 科学出版社

Probability, Statistics and Random Processes for Electrical Engineering, Alberto Leon Garcia, University of Toronto


参考网址: <http://www.randomservices.org/random/>







2026随机过程（二教... 群号: 1041739702



●上课时间及教室：

**周一下午 16:20-17:55(7-8节),
沙河校区二楼306(8班)**

**周三下午 16:20-17:55(7-8节),
沙河校区二楼306(8班)**

课程组相关说明:

- 1.教材：徐全智，《随机过程及应用》，高等教育出版社，2013.
- 2.成绩构成：平时（50%）+期末（50%）
平时成绩：考勤、课堂表现（10%）+
作业（30%）+小论文（10%）
- 3.考试方式：一页纸(盖有数学学院章)+闭卷



2026 年 7 月 23 日，在美国费城国际数学家大会，王虹获得菲尔兹奖，是历史上第 3 位女性菲尔兹奖得主，也是**第一位中国籍女性菲尔兹奖获得者**。



基本履历

- 本科：北京大学 2007 级，先就读**地空学院**，**大二转入数学科学学院**，2011 年本科毕业
- 海外求学：巴黎综合理工学院工程师、巴黎-萨克雷大学硕士（2014）
- MIT 博士（2019），导师：Larry Guth（拉里·古思）
- 普林斯顿高等研究院博士后
- 现任职位：纽约大学柯朗数学研究所正教授
- 法国高等科学研究所 IHES 终身教授（该所首位亚裔女性终身教授）

研究方向：


调和与分析、**几何测度论**，核心围绕傅里叶分析、集合几何、振荡积分等重大猜想开展研究。





Sōichi Kakeya
挂谷宗一

“n维空间里的挂谷集，其豪斯多夫维数必须是满满的n维。”



获奖核心成就：攻克百年数学难题 “三维挂谷猜想”

王虹获此殊荣，核心原因是她与合作者约书亚·扎尔 (Joshua Zahl) 共同攻克了困扰数学界逾百年的“三维挂谷猜想” (Kakeya conjecture)。

- 猜想背景：挂谷猜想源于1917年日本数学家挂谷宗一提出的一个趣味问题：

一根无限细的针，在平面上旋转180度或360度，扫过的最小面积是多少？

这一看似简单的问题后来被推广到高维空间，核心演变为：在n维空间中，一个包含所有方向单位线段的集合，其分形维数是否一定等于n？二维情形在1971年被证明，但三维情形却像铜墙铁壁，阻挡了包括布尔甘、沃尔夫、陶哲轩等顶尖数学家数十年。

- 证明过程：王虹和扎尔引入了一种全新视角，**将这些复杂交织的“针”在不同尺度下拆解成“颗粒”，从而证明其维度必须为3**。她们的证明分三篇系列论文，其中2025年2月发表在预印本网站arXiv上的完整证明长达127页。

荣誉与影响

- 这项成果被誉为“百年一遇”，对调和与分析/几何测度论等多个领域产生了深远影响；
- 王虹的成功打破了大众对顶尖数学家“年少竞赛成名”的固有印象，**证明了凭借长久的热爱、诚心坚守和直面难题的韧劲，同样能在基础数学领域取得世界级突破。**
- 王虹的事迹极大地鼓舞了年轻一代，尤其是女性投身科学研究的热情。





三角形逐级叠合方法表

级数	重叠系数	个/颗数	省下面积
切开后 (起点)	—	2^M	—
第 1 级	$\frac{2}{3}$	2^{M-1}	$\frac{1}{3}$
第 2 级	$\frac{3}{4}$	2^{M-2}	$\frac{1}{4}$
第 3 级	$\frac{4}{5}$	2^{M-3}	$\frac{1}{5}$
...	...	...	...
第 i 级	$\frac{i+1}{i+2}$	2^{M-i}	$\frac{1}{i+2}$
...	...	...	...
第 M 级 (终点)	$\frac{M+1}{M+2}$	1 (佩龙树)	$\frac{1}{M+2}$

“一根长度为 1 的线段，旋转过 180 度，或 360 度，所扫过的最小面积是 0。”

挂谷宗一的“趣味问题”与“反直觉的结论”：
如果针绕着它的中点旋转，扫过的是一个半径为 0.5 的圆，
面积是 $\pi/4 \approx 0.785$. 如果绕着针尖旋转，面积是 $\pi \approx 3.14$.

反直觉的真相：1928 年，苏联数学家贝西科维奇
(Besicovitch) 证明了，扫过的面积可以无限趋近于 0。



包含所有方向单位线段的集合被称为“挂谷集”



Dr. Hong Wang (王虹) 2026年菲尔兹奖获奖理论

高中生

她用数学证明了：一根长度为 1 的针，在三维空间里朝所有方向旋转。即使你用最精妙的折叠和穿插方式，把它“扫过”的体积挤压到几乎为零，这个集合的微观分形结构也绝不可能被无限压缩——它的分形维度必须是满满的三维。

数学告诉你，高维空间具有不可摧毁的“几何刚性”。

大学生

包含所有方向单位线段的集合被称为“挂谷集”。虽然挂谷集的体积可以被压缩至零（类似分形），但王虹与合作者严格证明了：三维挂谷集的豪斯多夫维数（Hausdorff Dimension）必须等于3。这打破了以往对高维几何稀疏性的幻想，揭示了相干干涉与方向分布在三维空间的几何约束下，不可能实现过度“藏匿”。

研究生

具体的三层数学解释：

基础：1919年贝西科维奇证明，可以通过精妙的线段重叠构造出**体积为零的挂谷集（包含所有方向的单位线段）**。

进阶：虽然体积可为零，但数学家猜想其微观“分形复杂度”（豪斯多夫维数）必须达到空间的全维数（挂谷猜想： n 维空间中维数必须为 n ）。





如何理解基础数学的“用”？

应用领域	核心应用场景	挂谷猜想的理论支撑与实际价值
医学成像	CT、MRI 图像重建	优化稀疏采样条件下的图像还原，在降低辐射剂量的同时，清晰勾勒微小病灶轮廓，减少成像伪影 1 4。
物理与电学	雷达遥感与 6G 通信	确立三维空间内电磁波束覆盖的理论极限，优化天线阵列布局，提升复杂环境下的信号抗干扰与高保真还原能力 2 11。
金融工程	系统性风险与高频交易	提供多维资源覆盖的几何优化思路，为极端市场条件下的风险预测、高频交易算法及投资组合优化提供底层理论约束 3 6。
人工智能	物理约束与深度学习	将调和和分析作为先验约束嵌入 AI 框架，解决数据驱动模型的“黑箱”难题，提升医学算法与高维数据处理的稳定性 1。

- **王虹解决三维挂谷猜想，不是直接造出 CT、雷达；而是证明了一条空间几何底层真理，解锁上面一整套信号处理数学工具，未来工程师基于这些新数学开发更好算法。**
- 王虹教授的突破，证明了任何试图在三维空间中覆盖所有方向的系统，都必须占据完整的空间容量。这一底层逻辑，正在从纯粹的数学象牙塔，悄然化作支撑**下一代医学影像、6G 通信与复杂系统调度的“隐形引擎”**。
- **王虹的研究属于纯粹的数学理论突破。**

历史上，很多基础的数学理论都是在诞生数十年甚至上百年后才显示出惊人的应用价值。比如，200年前为研究方程而发展的伽罗瓦域理论，如今成为了CD光盘纠错和二维码技术的基石；100多年前的傅里叶变换，如今也是现代手机通信和医学影像的核心。





“随机过程”的发展史

“随机过程”的英文 Stochastic Process，其词源和学科概念的起源是两条并行的线索：一个来自古老的希腊语词根，另一个则源于20世纪初物理学与数学的交叉。

词源学起源：“Stochastic” 的希腊语根


单词 Stochastic 的源头可以追溯到古希腊。

- 它来自希腊语 στόχος (stókhos)，原意是“目标”、“靶子”或“猜测”。
- 由此派生的动词 στοχάζομαι (stokházomai) 意为“瞄准”、“猜测”或“推断”。
- 在拉丁语中，它被转写为 stochasticus，并最终进入英语。

这个古老的词根本身就蕴含了与概率、不确定性、有目的地进行猜测相关的最朴素思想。



随机过程发展史关键节点



随机过程发展史关键节点

section 萌芽：物理驱动

1827 : 布朗观察花粉微粒不规则运动

1900 : Bachelier博士论文提出布朗运动金融模型

1905 : Einstein发表论文量化解释布朗运动(给出物理解释)

section 奠基：马尔可夫链与理论构建

1906 : A.A. 马尔可夫提出“马尔可夫链”概念

1923 : N. 维纳给出布朗运动严格数学定义

1931 : A.N. 柯尔莫哥洛夫《概率论的解析方法》奠定马尔可夫过程理论基础

section 体系化：公理与集大成

1933 : A.N. 柯尔莫哥洛夫《概率论基础》建立概率论公理化体系

1951 : K. 伊藤清创立随机微分方程理论

1953 : J.L. 杜布《随机过程论》系统化整个理论





第一幕：物理学的种子——布朗运动

随机过程的思想，最早源于对一种物理现象的着迷。1827年，植物学家布朗在显微镜下观察到花粉微粒在水中的无规则运动，这就是著名的**布朗运动**。

- **爱因斯坦的量化**：直到1905年，爱因斯坦从分子运动论的角度，首次对布朗运动进行了**量化分析**，证明了它的存在是分子无规则热运动的直接证据。这为随机过程提供了物理现实基础。

- **巴谢利耶的远见**：

几乎同时，法国数学家巴谢利耶（L. Bachelier）在其1900年的博士论文《投机理论》中，开创性地用布朗运动来描述股票和期权价格的变化，这被视为现代金融数学的起点，但其价值在当时被严重低估。

第二幕：理论的基石——马尔可夫链与柯尔莫哥洛夫

如果说布朗运动是灵感，那么将灵感化为理论，则依赖于几位数学巨匠。

• 马尔可夫与他的“链”：

俄国数学家**马尔可夫** (A.A. Markov) 在1906年前后，为证明变量间的独立性并非极限定理成立的必要条件，构造了一个新的概率模型。

在这个模型中，未来状态的发生概率只依赖于当前状态，而与更久远的历史无关。**这种“无记忆”的特性**，如同链条环环相扣，被后人称为**马尔可夫链**。这是第一个被严格定义和研究的随机过程模型。



第二幕：理论的基石——马尔可夫链与柯尔莫哥洛夫

• 柯尔莫哥洛夫与公理化大厦：

如果说马尔可夫提供了关键砖石，那么**柯尔莫哥洛夫** (A.N. Kolmogorov) 则建造了整个理论的大厦。

• 1931年的奠基：

他发表了论文《概率论的解析方法》，首次为马尔可夫过程奠定了坚实的理论基础。

• 1933年的革命：

他出版了划时代的著作《概率论基础》。在这本书中，他创造性地运用**测度论**，为概率论建立了**公理化体系**。

从此，**概率论和随机过程**拥有了像欧几里得几何一样严谨的逻辑起点，这是现代概率论的诞生标志。



第三幕：体系化与蓬勃发展

在柯尔莫哥洛夫奠定的基础上,随机过程迎来了它的黄金时代。

- **杜布的系统化：**

美国数学家**杜布** (J.L. Doob) 在1953年出版了经典著作《**随机过程论**》，系统且严格地总结了当时随机过程的基本理论。他还深入研究了**鞅论**，为随机过程的分析提供了更强大的工具。

- **伊藤清的革新：**日本数学家**伊藤清** (K. Itô) 在1951年左右，创立了关于布朗运动的**随机微分方程** (Itô calculus) 理论。

这一理论为处理连续时间、连续状态的随机过程（特别是金融资产定价）提供了数学利器，其影响深远，甚至催生了诺贝尔经济学奖。



核心人物与贡献汇总

关键人物	活跃时期	标志性贡献	核心意义
A.A. 马尔可夫	20世纪初	提出马尔可夫链模型	创建了第一个被严格定义的随机过程模型，开创了“无记忆”的随机系统分析。
A.N. 柯尔莫哥洛夫	20世纪30年代	1. 建立概率论公理化体系 2. 奠定马尔可夫过程理论基础	使概率论成为一门严谨的数学分支，为整个随机过程理论提供了统一的逻辑框架。
N. 维纳	20世纪20年代	给出布朗运动的严格数学定义	将物理现象转化为严谨的数学模型，其成果成为随机积分理论的重要基础。
K. 伊藤清	20世纪50年代	创立随机微分方程 (Itô calculus)	为处理连续时间的复杂随机系统提供了革命性的分析工具，是现代金融数学的基石。
J.L. 杜布	20世纪50年代	出版《随机过程论》，系统化鞅论	集大成式地总结了随机过程的理论体系，推动了鞅论等子领域的成熟。

时间线：物理赌博起源 → 马尔可夫链 → 布朗运动严格化 → 鞅理论 → 伊藤随机积分 → 现代随机过程 (AI、金融)



概率论 = 关于随机变量的学问

研究的核心对象：一个或多个随机变量 $X_1, X_2, \dots, X_n$

研究问题：

- 这个随机变量服从什么分布？
- 它的期望、方差是多少？
- 多个随机变量之间的相关系数是多少？
- 样本均值收敛到总体均值吗？（大数定律）
- 样本均值的分布趋近于什么？（中心极限定理）


数学框架：

- 一个概率空间 $(\Omega, \mathcal{F}, P)$
- 一个映射 $X: \Omega \rightarrow \mathbb{R}$?

关键词：分布、期望、方差、独立性、收敛性、假设检验

时间维度：无。所有随机变量都在同一个固定时间点或试验条件下被考虑。

一、研究对象





序 言

一、研究对象

事物的
变化过
程

确定性过程：确定形式的变化过程，即可用一个参数的确定函数来描述。

随机过程：不能用一个参数的确定函数描述，对此变化过程重复观察时，所得到参数的函数不尽相同。

如固定某一观测时刻 t ，事物在时刻 t 出现的状态是随机的，即**关注随机现象随时间推移的演变过程**

确定性过程：1) 真空中自由落体,下落的路径便可表为： $S = \frac{1}{2}gt^2$
2) 电容器通过电阻放电时,电容两端电位差随时间的变化就是一个确定性函数。





序 言

一、研究对象

事物的变化过程 { 确定性过程: 确定形式的变化过程, 即可用一个参数的确定函数来描述
随机过程:

不能用一个参数的确定函数描述, 对此变化过程重复观察时, 所得到参数的函数不尽相同。

如固定某一观测时刻 t , 事物在时刻 t 出现的状态是随机的, 即关注随机现象随时间推移的演变过程

例如:

1) 抛硬币实验 $\{X_n\}$: X_n 表示第 n 次硬币的正反面出现的次数。

$\{X_1, X_2, \dots, X_n, \dots\}$ 是一个过程, 关于离散时间参数 n .



2) 电话呼叫实验, 用 $X(t)$ 表示在时刻 t 前电话局接到的呼叫次数。如固定 t , 则 $X(t)$ 为一个随机变量, 但是 t 是可变参数, 是一个连续变量, 所以 $\{X(t)\}$ 又是一个过程。

一个形象的比喻

概念	比喻
随机变量	你站在一个地方拍一张照片, 照片里记录的是某个时刻的随机景象。
随机过程	你用摄像机连续录像, 录下的是整个时间序列的动态随机影像。



总结对比表

对比项	随机变量	随机过程
参数	无时间参数	时间参数 t
观测结果	单个数值	整条轨迹
概率描述	一个分布 $F_X(x)$	有限维分布族 $F_{t_1, \dots, t_n}(x_1, \dots, x_n)$
典型例子	掷骰子、身高、考试成绩	股票价格、气象数据、语音信号
AI应用	分类/回归中的标签	时间序列、语音、文本生成

在机器学习中，大部分任务都是在处理“随机变量”的推断问题；

而时间序列预测、强化学习、语音识别等任务，本质上都是在建模“随机过程”的结构规律。





经典案例：掷骰子

- X = 一次掷骰子的点数, $X \in \{1, 2, 3, 4, 5, 6\}$
- 分布: $P(X = k) = 1/6, k = 1, \dots, 6$
- 你每次掷骰子, 得到的是一个“随机变量的一次实现”。

经典案例：股票价格

- $\{S_t, t \geq 0\}$ 表示某股票在 t 时刻的价格。
- 一次观测: 不是得到某个固定价格, 而是得到一条**价格走势曲线**。
- 在不同时刻之间, 价格存在自相关性(如几何布朗运动模型)。

AI / 机器学习中的对照

1. 监督学习中的静态随机变量

在图像分类中，一张图片的标签 Y 是一个随机变量：

$$P(Y = \text{猫} \mid X = \text{图片}) = 0.92$$

这里**没有时间维度**，是一次静态推断。

2. 时间序列预测中的随机过程

在股票价格预测中， $\{S_t\}$ 是一个随机过程：

- 输入是历史序列 $S_{t-1}, S_{t-2}, \dots$
- 输出是未来价格 S_t 的分布
- 模型需要在**时间维度**上捕捉依赖关系（如LSTM、



3. 强化学习中的随机过程

马尔可夫决策过程 (MDP) 是一种特殊的随机过程：

$$S_{t+1} \sim P(\cdot, | S_t A_t)$$

- S_t 是状态随机过程
- 每一步的状态依赖于前一步，形成一条**随机轨迹**

4. 大语言模型中的随机过程视角

LLM生成文本时：

- 固定时刻 t ，下一个词 X_{t+1} 是一个随机变量
- 整个生成过程 $\{X_1, X_2, \dots, X_T\}$ 是一个**离散时间随机过程**
- **一次生成：得到一条完整的文本序列（样本路径）**

在机器学习中，大部分任务都是在处理“随机变量”的推断问题；而时间序列预测、强化学习、语音识别等任务，本质上都是在建模“随机过程”的结构规律。





序 言

一、研究 对 象

随机过程

在许多实际问题中, 不仅需要对随机现象做特定时间点上的一次观察, 且需要连续不断的观察研究对象随时间推移的演变过程.





例1：设 $X(t)$ 为信号流，它满足方程： $X(t+1)=aX(t)+\delta(t)$ ，其中 a 为实参数， $\delta(t)$ 代表误差. 真正的信号 $aX(t)$ 并不可能观测到. 人们所能观测到的是 $Y(t)=X(t)+Z(t)$, $Z(t)$ 为噪声.

从观测值 $Y(t)$ 出发，检测出 $X(t)$ 是通信工程中的重要课题. 这是过程的预测与滤波问题.

例2：英国植物学家Brown注意到漂浮在液面上的微小粒子不断进行不规则的运动。这种运动叫做Brown。它是分子大量随机碰撞的结果。

若记 $(X(t), Y(t))$ 为粒子在平面坐标上的位置，则它是平面上的Brown运动。在统计物理中对它有深入的研究。

现象特点：关注一族随时间或地点变化的随机变量，有自身的统计规律，而且变量间有着内在的关联关系.



随机过程：

研究和描述随机现象随时间演变的统计规律。

一族随时间变化的随机变量，是概率论向时间维度的延伸。



一个直观的比喻

- **概率论**：你站在一个路口，拍一张照片。照片里有一辆车，这辆车是红色还是蓝色？这是随机变量。
- **随机过程**：你用摄像机连续录像，记录了整条马路上所有车辆经过的动态过程。每一帧里的车是随机变量，但视频本身是随机过程——它包含了时间维度的结构和依赖关系。



随机过程：

研究和描述随机现象随时间演变的统计规律.

一族随时间变化的随机变量, 是概率论向时间维度的延伸.

二、研究方法

案例：

细菌繁殖模型(纯生过程 / Yule(尤尔)过程), 是概率论中**生灭过程**的经典案例(英国统计学家 Udeny Yule 在 1924 年提出的).

它展示了同一现象在**确定性**和**随机性**两种视角下的数学描述差异.

细菌繁殖模型 (纯生过程 / Yule过程) 不仅是生灭过程 (Birth-Death Process) 的经典案例, 更是整个连续时间马尔可夫链 (CTMC) 和排队论中最基础、最重要的基石之一.



Ex. 设某种细菌群体的个数在时段 $(t, t+\Delta t)$ 内只能增加, 增加的数量与 t 时刻的细菌数成正比, 且 $x_0=x(0)>0$.
(纯生过程: 只有“生”, 没有“死”, 出生率与当前数量成正比)

1) 确定性方法

设 t 时刻的细菌数为 $x(t)$, 有

$$\Delta x(t) = \lambda x(t) \Delta t, \quad (\lambda > 0).$$

令 $\Delta t \rightarrow 0$ 得微分方程 $\frac{dx(t)}{dt} = \lambda x(t)$

解得实值连续函数

$$\underline{x(t) = x_0 e^{\lambda t}}, t \geq 0. \text{ (确定性过程)}$$



二、研究方法

2) 随机性方法

设时刻 t 细菌数为随机变量 $X(t)$, 设 $(t, t+\Delta t)$ 内增加的细菌数与 Δt 有关而与 t 无关,

在 $X(t)=x$ 条件下, $X(t+\Delta t)$ 变为 $x+1$ 个的概率为

$$P\{X(t+\Delta t) = x+1 | X(t) = x\} = \lambda x \Delta t + o(\Delta t)$$

又设 $(t, t+\Delta t)$ 内增加不少于两个细菌的概率为 $o(\Delta t)$

根据全概率公式 $P(A) = \sum_{i=1}^n P(AB_i) = \sum_{i=1}^n P(B_i)P(A | B_i)$

$$\begin{aligned} P\{X(t+\Delta t) = x\} &= \lambda(x-1)\Delta t P\{X(t) = x-1\} \\ &+ (1 - \lambda x \Delta t) P\{X(t) = x\} + o(\Delta t) \end{aligned}$$



$$P\{X(t + \Delta t) = x\} = (1 - \lambda x \Delta t)P\{X(t) = x\} \\ + \lambda(x - 1)\Delta t P\{X(t) = x - 1\} + o(\Delta t)$$

令 $\Delta t \rightarrow 0$, 得
$$\frac{P(X(t + \Delta t) = x) - P(X(t) = x)}{\Delta t}$$

$$\frac{d}{dt}P(X(t) = x) = -\lambda x P\{X(t) = x\} + \lambda(x - 1)P\{X(t) = x - 1\}$$

初始条件为
$$P\{X_0 = x\} = \begin{cases} 1, & x = x_0; \\ 0, & x \neq x_0. \end{cases}$$

解得：生灭过程，即连续参数绝对分布)

$$P\{X(t) = x\} = C_{x-1}^{x-x_0} e^{-\lambda x_0 t} (1 - e^{-\lambda t})^{x-x_0}, \quad x \geq x_0$$

对比: $x(t) = x_0 e^{\lambda t}, t \geq 0$. (确定性过程)

$$P\{X(t) = x\} = C_{x-1}^{x-x_0} e^{-\lambda x_0 t} (1 - e^{-\lambda t})^{x-x_0}, x \geq x_0$$

注 与确定性结果不同处

1) 在固定时刻 t 未给出确定的细菌数, 给定 t 时刻的概率分布: $P\{X(t) = x\}$.

2) 细菌个数 $X(t)$ 随时间 t 的推移而改变, 是一族随机变量, 需研究其统计规律性.



对比总结表

维度	确定性模型	随机性模型	对应原案例
输出	单个确定值	一个概率分布	$x(t)$ vs $P(X(t) = x)$
数学工具	常微分方程 (ODE)	主方程 (Master Equation)	$\frac{dx}{dt} = \lambda x$ vs $\frac{dP}{dt} = -\lambda x P + \lambda(x-1)P$
不确定性	无	有 (方差、置信区间等)	细菌数在固定时刻的波动
代表方法	ODE / 确定性神经网络	SDE / 贝叶斯神经网络 / Diffusion	确定性 vs 随机性建模



机器学习中的类似对比

场景：逻辑回归（Logistic Regression）

建模方式	数学表达	输出结果	适用场景
确定性模型	$y = \sigma(\mathbf{w}^T \mathbf{x}), \quad \sigma(z) = \frac{1}{1 + e^{-z}}$	输出一个确定性的概率值， 如 0.7	普通分类任务， 认为输入唯一决定输出
随机性模型	$y \sim \text{Bernoulli}(\sigma(\mathbf{w}^T \mathbf{x}))$	输出一个随机变量，比如以 0.7 概率为 1， 0.3 概率为 0	贝叶斯逻辑回归、 需要量化不确定性的任务



深度学习中的类似对比

场景：Dropout 正则化

建模方式	数学表达	输出结果	适用场景
确定性模型	训练时固定 Dropout 率为 0.5 ，测试时乘以 0.5 补偿	输出一个确定性的激活值	标准训练流程
随机性模型	测试时保留 Dropout ，多次 前向传播取平均	输出激活值的 概率分布，得到 预测置信区间	MC-Dropout ，用于不确定性估计



大语言模型（LLM）中的类似对比

场景：文本生成（Text Generation）

建模方式	数学表达	输出结果	适用场景
确定性模型	greedy decoding: $y_t = \arg \max P(y_t y_{<t})$	输出唯一确定的文本序列	摘要、翻译等追求确定性的任务
随机性模型	temperature sampling: $y_t \sim P(y_t y_{<t})$	每次生成不同的文本序列，构成一个“文本分布”	创意写作、对话系统等需要多样性

GPT 类模型本质上是**条件概率分布**的建模。

当你在 ChatGPT 中将 temperature 设为 0，模型退化为确定性；而调高 temperature，模型就从该分布中随机采样，产生多样化的输出

总结：确定性 vs 随机性建模的选择

- **确定性模型**：在数据充足、系统相对稳定、追求效率的场景下表现良好（如传统物理、大规模部署）。
- **随机性模型**：在数据稀缺、需要不确定性量化、或需要多样性输出的场景中更具优势（如贝叶斯统计、生成式AI）。

你研究的细菌繁殖案例，正是这种概率建模思想的最佳入门范例。

下一次，当你看到某个模型在预测时给出一个“概率”时，不妨思考一下：这个概率是确定性的输出（如逻辑回归），还是真正意义上的随机变量（如贝叶斯模型）？

概率统计的应用体系通常包含三个递进层次¹：

层次	核心任务	解决的问题	典型应用场景
概率论	建立描述不确定性的数学语言	给定模型，预测结果发生的可能性	天气预报、风险评估、保险精算
数理统计	从数据反推分布规律	给定数据，推断背后的模型参数	市场调研、A/B测试、质量控制
随机过程	研究随时间演化的随机现象	追踪动态系统的状态变化	金融资产价格建模、信号处理、排队系统

随机过程在AI、深度学习和机器学习中的应用前景及未来展望



要理解它的前景，可以先看它在四个关键领域的核心应用，以及和AI结合的范式。



随机过程是描述**动态随机系统**的数学框架。它无处不在——从股价的起伏、通信信号的传输，到AI生成文本的逐词采样。

领域	核心任务	经典模型/案例	与AI/ML的结合范式
金融工程	资产定价、风险管理	几何布朗运动 (GBM) Black-Scholes公式的基石	深度强化学习：学习最优交易策略与投资组合对冲
通信与信号处理	信号检测、信道估计	马尔可夫链 与 高斯过程 Wiener滤波、卡尔曼滤波	学习驱动滤波：用RNN替代传统卡尔曼滤波进行状态跟踪
排队论与运筹	系统优化、资源调度	生灭过程 M/M/1队列（机场安检、呼叫中心）	深度强化学习：用于自适应调度（如数据中心任务分配）
生物与医学	种群演化、疾病传播	Yule过程（纯生过程） 传染病SIR模型	时序神经网络：用LSTM拟合SEIR模型参数，预测疫情趋势



与AI/ML/深度学习的融合点

扩散模型 (Diffusion Model)，就是随机过程与深度学习结合的典型产物：它通过**前向过程**不断向数据中注入噪声（马尔可夫链），再用神经网络学习**逆向过程**以恢复数据，目前是图像生成的主流技术。

其他重要的结合点包括：

- **状态空间模型**：用高斯过程或马尔可夫链对时间序列进行建模，并用贝叶斯深度学习推断隐状态
- **神经随机微分方程**：将神经网络嵌入SDE框架，用于处理不规则时间序列
- **图神经网络 + 马尔可夫随机场**：用于时空预测（如交通流、气象预报）



前沿领域与前景展望

- **生成式AI（扩散模型）**：目前最前沿的图像、视频生成技术，背后是随机过程的逆向求解。
- **AI for Science**：用随机过程约束神经网络，使其符合物理定律（物理信息神经网络）。
- **大模型 + 随机过程**：用随机过程对LLM的不确定性进行量化，提升输出可靠性。
- **时序基础模型**：开发能够跨领域、跨任务处理时序数据的通用模型

总结

- 随机过程提供了**数学基础**，让我们能够描述和预测随机演化系统。
- AI/ML/DL提供了**计算引擎**，让我们能够从大规模数据中学习这些过程的参数和结构。
- 两者的结合，正成为理解和生成复杂动态世界的**关键方法论**

概率统计、随机过程不仅是数学课本上的公式，更是支撑现代社会运转的底层逻辑。

不具备扎实的概率统计、随机顾虑基础，很难真正理解AI的运作机制。



💡 总结：顶级学者的“双手互搏”

在你的极值理论研究中，这两只手同样缺一不可：

1. **当你推导 $TM_{k_n}(t)$ 的渐近等价量时**，你必须紧紧使用**左手**。你要在 $\mathcal{L} \cap \mathcal{D}$ 类中运用测度论，确保每一步放缩、每一个极限交换都绝对严谨，无懈可击。
2. **当你解释为什么要在保险中应用二阶近似时**，你必须切换到**右手**。你要告诉审稿人和业界：“虽然一阶近似在数学上已经足够，但在真实的极端灾难（如澳大利亚汽车索赔）面前，一阶近似忽略了尾部离散度。二阶近似在物理直观上，捕捉到了那 55 次极端索赔背后隐藏的‘风险聚集性’。”

左手保证了你的论文“不会被数学界挑出毛病”，而右手保证了你的论文“不会被业界扔进垃圾桶”。



“AI 幻觉 (Hallucination) ” 是指人工智能 (尤其是生成式大语言模型) 在生成内容时, 会自主编造出看似逻辑通顺、语言流畅、内容合理, 但实际上完全脱离事实、无现实依据的虚假信息, 且模型往往会以极度自信的语气输出这些内容, 甚至默认自身生成的内容是真实有效的^{1 4}。

1. AI 产生 “幻觉” 的底层逻辑

AI 产生幻觉并非简单的 “技术小bug”, 而是其底层架构带来的必然问题, 主要归因于以下三个深层原因:

- **概率预测机制**: 大语言模型本质上是一台极其复杂的 “文字接龙机”, 它并不真正 “理解” 文字的含义, 而是根据海量文本学习词语间的统计关联, 通过计算概率来预测 “下一个最可能出现的词”。
- **训练数据的局限与污染**: AI 的知识全部来自训练数据。如果训练数据中存在缺口、滞后性, 或者互联网上本身就包含大量错误、偏见甚至虚假数据 (如 “数据投毒”), AI 就会学习这些错误信息, 导致 “先天不足”^{4 5}。
- **不合理的 “考试制度”**: 现行的多数模型评测采用二元评分 (答对得分, 答错或不答得零分)。在这种规则下, “永远猜一个答案” 在数学上成了最优策略, 导致模型被塑造成了宁可给出过度自信的猜测, 也不愿承认自己不确定⁴。





3. 现实危害与典型案例

“AI 幻觉”已从网络信息领域渗透至现实社会各个层面，甚至直接威胁人身安全与司法公正：

- **法律领域的虚假文书**：全球多国法院陆续发现，部分律师过度依赖 AI 撰写法律文书，导致援引虚假判例、虚构法官观点。例如，美国纽约南区联邦法院审理的“ChatGPT法律幻觉第一案”中，原告律师借助 AI 提交了至少6起凭空捏造的航空业判例，最终被法官认定存在主观过错并处以罚款¹。
- **侵权与名誉损害**：国内首例因“AI 幻觉”引发的侵权案中，AI 平台在生成错误的高校报考信息后，竟底气十足地承诺“若内容有误将赔偿10万元”；另有律师在检索个人信息时，被 AI 虚构了“被判三年有期徒刑”的不实内容^{1 2}。
- **实体设备的安全隐患**：在自动驾驶和人形机器人领域，AI 一旦产生“感知幻觉”，会误判道路环境或下达错误操作指令，直接引发人身和财产安全事故¹。

